Manipulation de données

Découverte de Pandas

Xavier Gendre

Pandas

Pandas est un module Python dédié à la manipulation et à l'analyse de données. Il s'agit d'un logiciel libre largement utilisé en Data Science.

L'alias `pd` est généralement utilisé pour le module `pandas`.

```
1 import pandas as pd
```

- Manipulation de nombreux formats (CSV, Parquet, HDF, ...).
- Intégration avec les modules scientifiques comme NumPy et les modules de Machine Learning comme Scikit-learn.
- Outils de visualisation de données.

Series

Pandas offre le type élémentaire `Series` pour représenter un objet *unidimensionnel* similaire à un vecteur et contenant des données de **même type**.

Un objet `Series` peut être créé à partir d'une liste et possède un type `dtype`.

```
1  s = pd.Series([1, 2, 3])
2  s
```

```
0    1
1    2
2    3
dtype: int64
```

Par défaut, les indices (`index`) d'un objet `Series` sont des entiers commençant à l'indice `0`.

Il est possible de préciser les indices à la création.

```
1 s = pd.Series([1, 2, 3], index=["A", "B", "C"])
2 s
```

```
A    1
B    2
C    3
dtype: int64
```

Cela peut aussi se faire avec un dictionnaire.

```
1 s = pd.Series({"A": 1, "B": 2, "C": 3})
2 s
```

```
A    1
B    2
C    3
dtype: int64
```

Index (`index`) et valeurs (`values`) peuvent être récupérés.

```
print(f"Index: {s.index}")
```

```
Index: Index(['A', 'B', 'C'], dtype='object')
```

```
print(f"Valeurs: {s.values}")
```

```
Valeurs: [1 2 3]
```

Un objet `Series` peut également avoir un nom (`name`) pour l'identifier dans un jeu de données.

```
s = pd.Series([1, 2, 3], index=["A", "B", "C"], name="X")
s
```

```
A    1
B    2
C    3
Name: X, dtype: int64
```

L’accès à la valeur d’un élément est possible par sa position ou son index.

```
print(s[1]) # Position
```

```
2
```

```
print(s["B"]) # Index
```

```
2
```

Un sous-objet `Series` s’obtient en passant une liste.

```
print(s[[0, 1]]) # Position (liste)
```

```
A    1
B    2
Name: X, dtype: int64
```

```
print(s[["A", "B"]]) # Index (liste)
```

```
A    1
B    2
Name: X, dtype: int64
```

Les objets `Series` permettent les opérations terme à terme.

```
1  s0 = pd.Series([1, 2, 3], index=["A", "B", "C"])
2  s1 = pd.Series([4, 5, 6], index=["A", "B", "C"])
```

```
1  s0 + s1
```

```
A    5
B    7
C    9
dtype: int64
```

```
1  s0 * s1
```

```
A     4
B    10
C    18
dtype: int64
```

```
1  2 * s0
```

```
A    2
B    4
C    6
dtype: int64
```

```
1  s0**2
```

```
A    1
B    4
C    9
dtype: int64
```

Il faut cependant faire attention aux index de chaque objet.

```
1  s0 = pd.Series([1, 2, 3], index=["A", "B", "C"])
2  s1 = pd.Series([4, 5, 6], index=["A", "B", "D"]) # Pas d'indice C
3
4  s0 + s1
```

```
A    5.0
B    7.0
C    NaN
D    NaN
dtype: float64
```

Pour le type numérique, des méthodes d'*agrégation* usuelles sont disponibles (`mean`, `var`, `min`, `max`, ...)

```
1  s0.mean()
```

```
2.0
```

```
1  s0.max()
```

```
3
```

DataFrame

Un jeu de données n'est généralement pas unidimensionnel et contient plusieurs colonnes de types différents à la façon d'un tableur informatique.

Avec Pandas, ces colonnes sont des `Series` et elles forment un objet `DataFrame`.

Un `DataFrame` est un objet central en Data Science. Les colonnes correspondent généralement à des **variables** et les lignes à des **observations**.

Création d'un DataFrame

Il existe plusieurs façons de créer un `DataFrame` dont l'utilisation d'un dictionnaire de listes :

```
df = pd.DataFrame({
    "Nombre": [1, 2, 3, 4],
    "Label": ["A", "B", "C", "D"],
    "X": [1.2, 3.4, 5.6, 7.8],
    "Bool": [True, False, False, True],
    "Nom": ["Bob", "Ken", "Ben", "Joy"]
})
print(df)
```

```
   Nombre Label    X   Bool  Nom
0       1     A  1.2   True  Bob
1       2     B  3.4  False  Ken
2       3     C  5.6  False  Ben
3       4     D  7.8   True  Joy
```

Un objet `DataFrame` permet un grand nombre de manipulations.

Les opérations suivantes font partie des plus importantes :

- **Sélection** de colonnes/variables,
- **Filtre** sur les lignes,
- **Tri** des lignes,
- **Mutation** pour créer ou modifier des colonnes,
- **Agrégation** pour résumer l'information.

Sélection

Il est possible de manipuler une colonne d'un `DataFrame` comme un objet `Series` par attribut (`df.X`) ou avec la syntaxe des listes (`df["X"]`).

```
print(df.X) # Objet Series
```

```
0    1.2
1    3.4
2    5.6
3    7.8
Name: X, dtype: float64
```

```
print(df["X"]) # Objet Series
```

```
0    1.2
1    3.4
2    5.6
3    7.8
Name: X, dtype: float64
```

Une liste de noms de colonnes permet d'extraire un sous-objet `DataFrame`.

```
print(df[["X", "Nom"]])
```

```
     X   Nom
0  1.2   Bob
1  3.4   Ken
2  5.6   Ben
3  7.8   Joy
```

La méthode `filter` sélectionne les colonnes par nom,

```
print(df.filter(items=["X", "Nom"]))
```

```
     X   Nom
0  1.2   Bob
1  3.4   Ken
2  5.6   Ben
3  7.8   Joy
```

par contenu,

```
print(df.filter(like="om")
```

```
   Nombre   Nom
0       1   Bob
1       2   Ken
2       3   Ben
3       4   Joy
```

ou par expression régulière.

```
print(df.filter(regex="l$"
```

```
  Label    Bool
0     A    True
1     B   False
2     C   False
3     D    True
```

Filtre

Filtrer les lignes se fait en passant une `Series` de booléens.

```
1 print(df[df.X < 5])
```

```
   Nombre Label    X   Bool  Nom
0       1     A  1.2   True  Bob
1       2     B  3.4  False  Ken
```

Pour combiner des conditions, il est possible d'utiliser les opérateurs `&` (**and**), `|` (**or**) et `~` (**not**).

```
1 print(df[((df.Label == "D") & df.Bool) | ~(df.X >= 5)])
```

```
   Nombre Label    X   Bool  Nom
0       1     A  1.2   True  Bob
1       2     B  3.4  False  Ken
3       4     D  7.8   True  Joy
```

Tri

La méthode `sort_values` permet de trier les lignes.

```
          1  print(df.sort_values(by="Nom"))
```

```
   Nombre Label    X   Bool  Nom
2       3     C  5.6  False  Ben
0       1     A  1.2   True  Bob
3       4     D  7.8   True  Joy
1       2     B  3.4  False  Ken
```

Plusieurs variables peuvent être passées à `sort_values` pour arbitrer les cas d'égalité.

```
df_dalton = pd.DataFrame({
    "Nom": ["Dalton", "Dalton", "Dalton", "Lincoln", "Dalton"],
    "Prenom": ["Joe", "William", "Jack", "Abraham", "Averell"],
    "Taille": [1.4, 1.67, 1.93, 1.93, 2.13]
})

print(df_dalton.sort_values(by=["Nom", "Prenom", "Taille"]))
```

```
      Nom   Prenom  Taille
4  Dalton  Averell    2.13
2  Dalton     Jack    1.93
0  Dalton      Joe    1.40
1  Dalton  William    1.67
3 Lincoln  Abraham    1.93
```

Mutation

Pour créer ou mettre à jour une colonne, il suffit de lui affecter des nouvelles valeurs.

```
1  df["NEW"] = [42, 43, 44, 45]
2  print(df)
```

```
   Nombre Label    X   Bool  Nom  NEW
0       1     A  1.2   True  Bob   42
1       2     B  3.4  False  Ken   43
2       3     C  5.6  False  Ben   44
3       4     D  7.8   True  Joy   45
```

```
1  df.X = df.X + df.Nombre
2  print(df)
```

```
   Nombre Label     X   Bool  Nom  NEW
0       1     A   2.2   True  Bob   42
1       2     B   5.4  False  Ken   43
2       3     C   8.6  False  Ben   44
3       4     D  11.8   True  Joy   45
```

La création de colonne se fait souvent à l'aide de la méthode `apply` qui permet d'appliquer une fonction sur chaque ligne (`axis=1`) ou sur chaque colonne (`axis=0`, défaut).

```
1 def f(row):
2     return 11 if row.Nom[0] == "B" else 22
3
4 df["F"] = df.apply(f, axis=1) # Sur les lignes
5 print(df)
```

```
   Nombre Label     X   Bool  Nom  NEW   F
0       1     A   2.2   True  Bob   42  11
1       2     B   5.4  False  Ken   43  22
2       3     C   8.6  False  Ben   44  11
3       4     D  11.8   True  Joy   45  22
```

```
1 print(df[["Nombre", "X", "Bool"]].apply(sum, axis=0)) # Sur les col
```

```
Nombre    10.0
X         28.0
Bool       2.0
dtype: float64
```

Pour réaliser une mutation, il est également possible d'utiliser la méthode `assign`.

```
print(
    df.assign(SUM=df.NEW + df.F)
)
```

	Nombre	Label	X	Bool	Nom	NEW	F	SUM
0	1	A	2.2	True	Bob	42	11	53
1	2	B	5.4	False	Ken	43	22	65
2	3	C	8.6	False	Ben	44	11	55
3	4	D	11.8	True	Joy	45	22	67

Agrégation

La méthode `agg` permet d'utiliser des *fonctions d'agrégation* sur les colones (ou sur les lignes).

```
print(
    df[["Nombre", "X", "Bool"]].agg(["count", "mean", "var"])
)
```

```
          Nombre           X      Bool
count   4.000000    4.000000  4.000000
mean    2.500000    7.000000  0.500000
var     1.666667   17.066667  0.333333
```

Il est aussi possible d'utiliser des *fonctions d'agrégation* différentes sur chaque colonne.

```
print(
    df[["Nombre", "X", "F"]].agg(
        {
            "Nombre": ["sum", "min"],
            "X": ["sum", "max"],
            "F": pd.Series.nunique
        }
    )
)
```

```
          Nombre     X    F
sum         10.0  28.0  NaN
min          1.0   NaN  NaN
max          NaN  11.8  NaN
nunique      NaN   NaN  2.0
```

Toute fonction qui s'applique à un objet `Series` peut être utilisée comme agrégateur :

- Pandas dispose des classiques :
  - `"count"`,
  - `"min"`/`"max"`,
  - `"sum"`/`"mean"`/`"median"`,
  - `"var"`/`"std"`,...
- `pd.Series.nunique` compte les valeurs distinctes,
- `pd.unique` retourne la liste des valeurs distinctes,
- fonctions personnalisées, ...

Formats standards

En pratique, les jeux de données proviennent de sources extérieures. Pandas permet de lire un grand nombre de formats standards :

- CSV avec `read_csv`,
- Parquet avec `read_parquet`,
- Excel avec `read_excel`,
- HDF avec `read_hdf`,
- ...

Le fichier `hflights.csv` contient un jeu de données relatif aux vols partant des aéroports de Houston : IAH (*George Bush Intercontinental*) et HOU (*Houston Hobby*).

```
1 hflights = pd.read_csv("data/hflights.csv")
2 hflights.dtypes
```

```
Year                 int64
Month                int64
DayofMonth           int64
DayOfWeek            int64
DepTime            float64
ArrTime            float64
UniqueCarrier       object
FlightNum            int64
TailNum             object
ActualElapsedTime  float64
AirTime            float64
ArrDelay           float64
DepDelay           float64
Origin              object
Dest                object
Distance             int64
```

La méthode `head` permet d'avoir un aperçu des données chargées.

```
1 print(hflights.head())
```

```
   Year  Month  DayofMonth  DayOfWeek  DepTime  ArrTime UniqueCarrier  \
0  2011      1           1          6   1400.0   1500.0            AA
1  2011      1           2          7   1401.0   1501.0            AA
2  2011      1           3          1   1352.0   1502.0            AA
3  2011      1           4          2   1403.0   1513.0            AA
4  2011      1           5          3   1405.0   1507.0            AA

   FlightNum TailNum  ActualElapsedTime  ...  ArrDelay  DepDelay  Origin Dest
\
0        428  N576AA               60.0  ...     -10.0       0.0     IAH  DFW
1        428  N557AA               60.0  ...      -9.0       1.0     IAH  DFW
2        428  N541AA               70.0  ...      -8.0      -8.0     IAH  DFW
3        428  N403AA               70.0  ...       3.0       3.0     IAH  DFW
4        428  N492AA               62.0  ...      -3.0       5.0     IAH  DFW

  Distance  TaxiIn  TaxiOut  Cancelled  CancellationCode  Diverted
```

Les données peuvent maintenant être manipulées.

La méthode `apply` fonctionne aussi sur les objets `Series` qui forment les colonnes du `DataFrame`.

Les fonctions anonymes (`lambda`) sont souvent utilisées dans ce cadre.

```
carrier_map = {
    "AA": "American",           "AS": "Alaska",     "B6": "JetBlue"
    "CO": "Continental",        "DL": "Delta",      "OO": "SkyWest"
    "UA": "United",             "US": "US_Airways", "WN": "Southwes
    "EV": "Atlantic_Southeast", "F9": "Frontier",   "FL": "AirTran"
    "MQ": "American_Eagle",     "XE": "ExpressJet", "YV": "Mesa",
}

hflights["UniqueCarrier"] = hflights.UniqueCarrier.apply(
    lambda carrier: carrier_map[carrier]
)
```

Données manquantes

La variable `CancellationCode` contient de nombreuses données manquantes encodées par `nan` du module `numpy` ou par `NA` de `pandas` selon les jeux de données.

```
1 hflights.CancellationCode.head()
```

```
0    NaN
1    NaN
2    NaN
3    NaN
4    NaN
Name: CancellationCode, dtype: object
```

```
1 hflights.CancellationCode.unique()
```

```
array([nan, 'A', 'B', 'C', 'D'], dtype=object)
```

La fonction `isna` permet de détecter ces données manquantes (la fonction `notna` fait le contraire).

```
1 pd.isna(hflights.CancellationCode).head()
```

```
0    True
1    True
2    True
3    True
4    True
Name: CancellationCode, dtype: bool
```

La méthode `dropna` supprime les données manquantes.

```
1 hflights.CancellationCode.dropna().head()
```

```
194    A
210    B
323    B
335    A
347    B
Name: CancellationCode, dtype: object
```

La méthode `fillna` permet de remplacer ces données manquantes par une valeur. L'argument `inplace` est commun à de nombreuses méthodes et il permet de mettre à jour le contenu du `DataFrame` sans affectation.

```
1 hflights.CancellationCode.fillna("", inplace=True)
2 print(hflights.head(2))
```

```
   Year  Month  DayofMonth  DayOfWeek  DepTime  ArrTime UniqueCarrier  \
0  2011      1           1          6   1400.0   1500.0      American
1  2011      1           2          7   1401.0   1501.0      American

   FlightNum TailNum  ActualElapsedTime  ...  ArrDelay  DepDelay  Origin Dest
\
0        428  N576AA               60.0  ...     -10.0       0.0     IAH  DFW
1        428  N557AA               60.0  ...      -9.0       1.0     IAH  DFW

  Distance  TaxiIn  TaxiOut  Cancelled  CancellationCode Diverted
0      224     7.0     13.0          0                         0
1      224     6.0      9.0          0                         0

[2 rows x 21 columns]
```

```
cancel_map = {
    "A": "carrier",
    "B": "weather",
    "C": "national air system",
    "D": "security",
    "": "not cancelled",
}

hflights["CancellationCode"] = hflights.CancellationCode.apply(
    lambda cancel_code: cancel_map[cancel_code]
)

hflights.CancellationCode.head()
```

```
0    not cancelled
1    not cancelled
2    not cancelled
3    not cancelled
4    not cancelled
Name: CancellationCode, dtype: object
```

Regroupement

Les données peuvent être groupées avec `groupby` selon des variables. Ceci est très souvent utilisé avec la méthode `agg`.

```
print( # Remarquer la syntaxe de cet exemple
    hflights
    .groupby(hflights.CancellationCode)
    .agg( # NamedAgg permet de nommer les agrégations
        FlightCount=pd.NamedAgg(column="FlightNum", aggfunc="count"
        DelayMean=pd.NamedAgg(column="DepDelay", aggfunc="mean"),
        DelayStd=pd.NamedAgg(column="DepDelay", aggfunc="std"),
    )
    .sort_values(by="FlightCount", ascending=False)
)
```

CancellationCode	FlightCount	DelayMean	DelayStd
not cancelled	224523	9.433065	28.759280
weather	1652	53.615385	58.146764
carrier	1202	45.250000	105.880133
national air system	118	53.500000	41.719300
security	1	NaN	NaN

Cela devient très utile avec les graphiques 📈

```
1 (
2     hflights.DepDelay
3     .groupby(hflights.UniqueCarrier)
4     .agg("mean")
5     .reset_index() # Index UniqueCarrier en colonne
6     .plot.scatter(x="UniqueCarrier", y="DepDelay")
7 )
```

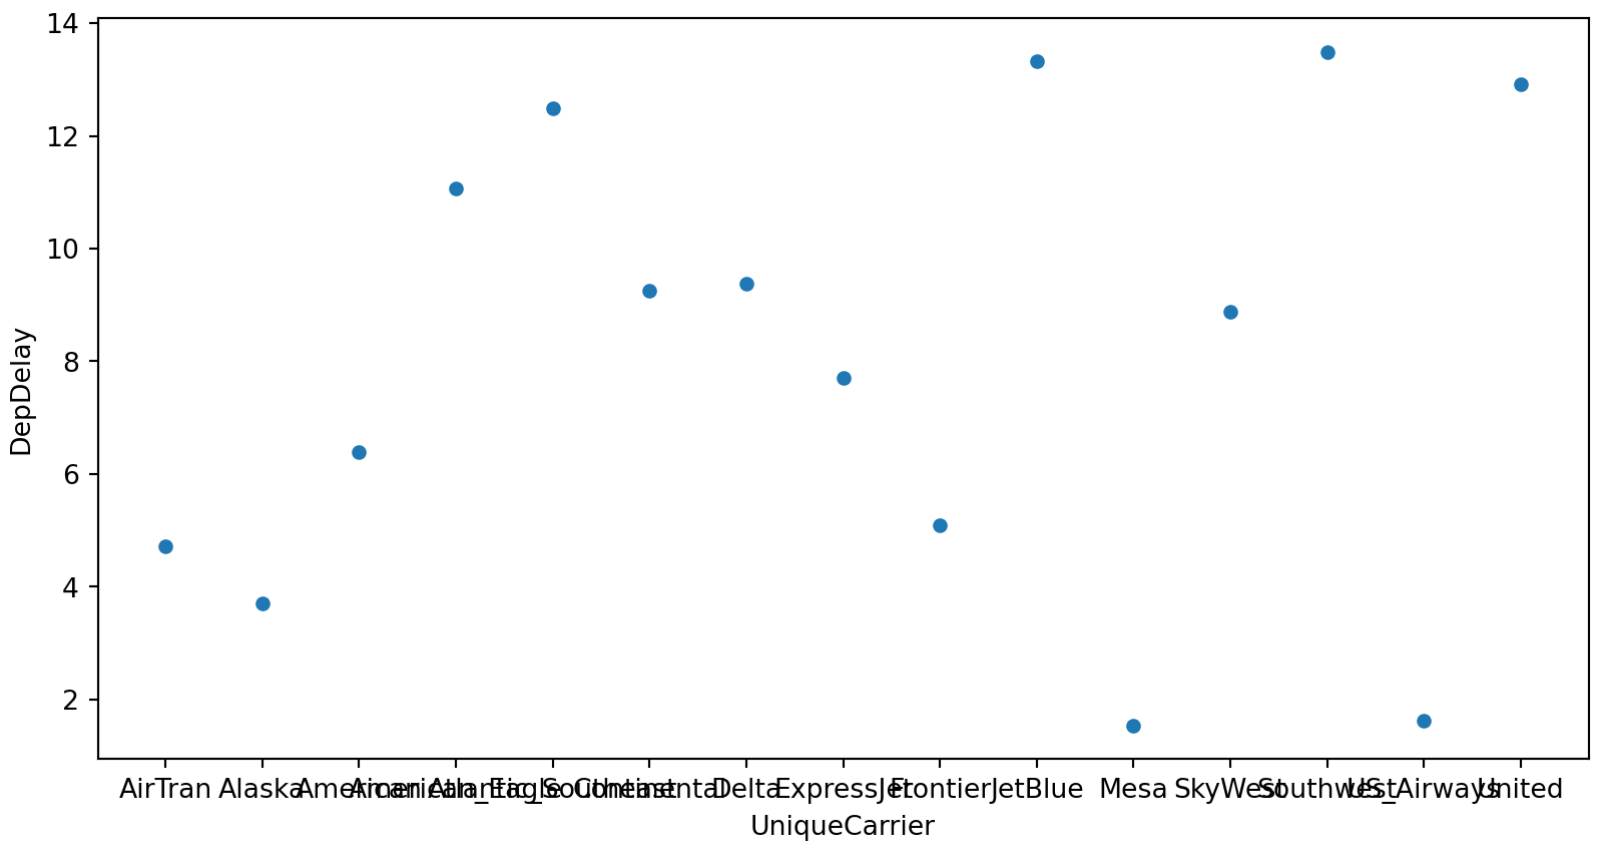

```
1  import numpy as np # Hello NumPy :-)
```

```
1  dep_delay_summary = (
2      hflights[
3          np.isfinite(hflights.DepDelay) # isfinite de NumPy
4          & (hflights.DepDelay > 0)
5          & (hflights.CancellationCode != "not cancelled")
6      ]
7      .groupby( # Groupement sur 2 colonnes
8          [hflights.CancellationCode, hflights.UniqueCarrier]
9      )
10     .agg(
11         count=pd.NamedAgg(column="FlightNum", aggfunc="count"),
12         min=pd.NamedAgg(column="DepDelay", aggfunc="min"),
13         max=pd.NamedAgg(column="DepDelay", aggfunc="max"),
14         med=pd.NamedAgg(column="DepDelay", aggfunc="median"),
15     )
16 )
17 print(dep_delay_summary.nlargest(2, "count")) # Tri + Filtre
```

```
                                  count  min    max   med
CancellationCode UniqueCarrier
weather          ExpressJet          13  1.0  173.0  64.0
carrier          ExpressJet           4  5.0  271.0  91.0
```

Mise en forme

Les jeux de données comme dans l'exemple précédent sont dits au **format long**.

```
print(dep_delay_summary.reset_index())
```

	CancellationCode	UniqueCarrier	count	min	max	med
0	carrier	AirTran	1	64.0	64.0	64.0
1	carrier	American	2	3.0	8.0	5.5
2	carrier	Atlantic_Southeast	1	220.0	220.0	220.0
3	carrier	Continental	1	187.0	187.0	187.0
4	carrier	Delta	1	42.0	42.0	42.0
5	carrier	ExpressJet	4	5.0	271.0	91.0
6	carrier	SkyWest	3	27.0	37.0	28.0
7	carrier	Southwest	3	1.0	548.0	3.0
8	carrier	US_Airways	1	153.0	153.0	153.0
9	carrier	United	1	110.0	110.0	110.0
10	national air system	Continental	1	24.0	24.0	24.0
11	national air system	ExpressJet	1	83.0	83.0	83.0
12	weather	Continental	2	26.0	156.0	91.0
13	weather	Delta	1	110.0	110.0	110.0
14	weather	ExpressJet	13	1.0	173.0	64.0

La méthode `pivot` permet de passer au **format large.**

```
format_large = dep_delay_summary.reset_index().pivot(
    index="CancellationCode",
    columns="UniqueCarrier",
    values="count"
)
print(format_large)
```

```
UniqueCarrier         AirTran  American  Atlantic_Southeast  Continental  \
CancellationCode
carrier                   1.0       2.0                 1.0          1.0
national air system       NaN       NaN                 NaN          1.0
weather                   NaN       NaN                 NaN          2.0

UniqueCarrier         Delta  ExpressJet  SkyWest  Southwest  US_Airways  United
CancellationCode
carrier                 1.0         4.0      3.0        3.0         1.0     1.0
national air system     NaN         1.0      NaN        NaN         NaN     NaN
weather                 1.0        13.0      3.0        NaN         1.0     NaN
```

Pivot

df

	foo	bar	baz	zoo
0	one	A	1	x
1	one	B	2	y
2	one	C	3	z
3	two	A	4	q
4	two	B	5	w
5	two	C	6	t

Stacked

```
df.pivot(index='foo',
         columns='bar',
         values='baz')
```

bar	A	B	C
foo			
one	1	2	3
two	4	5	6

Record

La méthode `melt` permet de revenir au **format long.**

```
print(
    format_large.reset_index()
    .melt(id_vars=["CancellationCode"], value_name="count")
)
```

	CancellationCode	UniqueCarrier	count
0	carrier	AirTran	1.0
1	national air system	AirTran	NaN
2	weather	AirTran	NaN
3	carrier	American	2.0
4	national air system	American	NaN
5	weather	American	NaN
6	carrier	Atlantic_Southeast	1.0
7	national air system	Atlantic_Southeast	NaN
8	weather	Atlantic_Southeast	NaN
9	carrier	Continental	1.0
10	national air system	Continental	1.0
11	weather	Continental	2.0
12	carrier	Delta	1.0
13	national air system	Delta	NaN
14	weather	Delta	1.0

Il ne reste plus qu'à utiliser `dropna`...

Melt

`df3`

	first	last	height	weight
0	John	Doe	5.5	130
1	Mary	Bo	6.0	150

```
df3.melt(id_vars=['first', 'last'])
```

	first	last	variable	value
0	John	Doe	height	5.5
1	Mary	Bo	height	6.0
2	John	Doe	weight	130
3	Mary	Bo	weight	150

Les méthodes `stack` et `unstack` jouent un rôle similaire à partir des indices.

```
1 stacked = dep_delay_summary.stack()
2 print(stacked)
```

```
CancellationCode  UniqueCarrier
carrier           AirTran         count      1.0
                                  min       64.0
                                  max       64.0
                                  med       64.0
                  American        count      2.0
                                             ...
weather           SkyWest         med       64.0
                  US_Airways      count      1.0
                                  min      135.0
                                  max      135.0
                                  med      135.0
Length: 68, dtype: float64
```

Stack

`df2`

		A	B
first	**second**		
bar	**one**	1	2
	two	3	4
baz	**one**	5	6
	two	7	8

MultiIndex

`stacked = df2.stack()`

first	**second**		
bar	**one**	**A**	1
		B	2
	two	**A**	3
		B	4
baz	**one**	**A**	5
		B	6
	two	**A**	7
		B	8

MultiIndex

```
1 unstacked = stacked.unstack()
2 print(unstacked)
```

		count	min	max	med
CancellationCode	UniqueCarrier				
carrier	AirTran	1.0	64.0	64.0	64.0
	American	2.0	3.0	8.0	5.5
	Atlantic_Southeast	1.0	220.0	220.0	220.0
	Continental	1.0	187.0	187.0	187.0
	Delta	1.0	42.0	42.0	42.0
	ExpressJet	4.0	5.0	271.0	91.0
	SkyWest	3.0	27.0	37.0	28.0
	Southwest	3.0	1.0	548.0	3.0
	US_Airways	1.0	153.0	153.0	153.0
	United	1.0	110.0	110.0	110.0
national air system	Continental	1.0	24.0	24.0	24.0
	ExpressJet	1.0	83.0	83.0	83.0
weather	Continental	2.0	26.0	156.0	91.0
	Delta	1.0	110.0	110.0	110.0

Unstack

`stacked`

first	second		
bar	one	A	1
		B	2
	two	A	3
		B	4
baz	one	A	5
		B	6
	two	A	7
		B	8

MultiIndex

`stacked.unstack()`

		A	B
first	second		
bar	one	1	2
	two	3	4
baz	one	5	6
	two	7	8

MultiIndex

À vous de jouer !